

基于 U-Net 神经网络的采煤塌陷类型识别

杨书平

(郑州科技学院,河南 郑州)

摘 要:针对地下煤炭资源被开采利用,出现大规模采空区,产生大面积沉陷,威胁到矿区的安全生产和人们的人身安全问题。本研究首先对鹤岗矿区遥感影像进行预处理、数据集的制作,然后用 U-Net 卷积神经网络训练模型,修改训练参数,进行塌陷坑、地裂缝、塌陷盆地的识别,整体精度达到 97.58%,表明此次模型训练结果较准确。从而得到鹤岗矿区地裂缝、塌陷坑、塌陷盆地的具体分布图,发现盆地的查准率最高,地裂缝识别效果其次,塌陷坑由于本身形状及特征的因素影响,识别的效果差于其他两类地物,分析上述三类地物的精度指标,证明了 U-Net 网络模型适合于本次研究的研究,为复垦、治理采空塌陷区提供基础资料具有重要的意义。

关键词:U-Net;深度学习;塌陷区识别;采煤塌陷区

中图分类号:TU921

文献标识码:A

文章编号:2096-4390(2025)18-0027-04

引言

煤炭露天开采引发产生的突发性地质灾害对周边环境都造成了较严重的破坏性,同时地质灾害也进一步制约着了整个矿区生态的全面可持续和谐发展,为全面保障煤炭矿区和谐稳定快速发展,需要采取措施对开采矿区地质灾害隐患进行及时防治。

早期对矿区采煤塌陷区域遥感影像资料监测与研究,主要组织形式均是直接通过计算机人工遥感图像解译,如我国鹿献章等^[1]科学家首次地利用了高分辨率的影像,识别出了我国煤矿采空区域的塌陷分布程度以及塌陷的范围,杨圣军等^[2]通过采用 Quickbird 遥感图像,进行目视影像的判读处理取了龙口矿区地面塌陷灾害的塌陷情况。但是这种识别方法只能用于大范围、大面积的塌陷分析,且这种分析效率低,准确度不高。

随着卷积神经网络算法的兴起,梁峰^[3]通过使用遥感技术和深度学习结合的技术对四川山区典型地质灾害进行识别。张堯^[4]通过用深度学习的方法将研究区的形变速率图和相干系数图作数据集,通过模型训练实现智能提取塌陷区。这些结果表明将遥感技术和深度学习结合在一起,不光能够提升识别准确率,还能大大提高工作效率。

1 研究区与研究数据

鹤岗市位于黑龙江省的东北部,本次研究的区域为鹤岗矿区,位于鹤岗市的东南部。

为提高采空塌陷地识别的准确性,本次课题选用的数据源为北京二号卫星数据,北京二号小卫星星座于 2015 年 7 月在印度 Satish Dhawan 空间中心发射,该星由 3 颗 0.8 米分辨率的光学遥感卫星组成,有 5 种成像模式。

2 U-Net 算法简介

卷积神经网络,带有卷积结构的神经网络,因卷积结构能够有效的减少影像处理过程中的参数个数,避免造成数据冗余现象,该网络模型通过迭代训练来增强精度。

U-Net 网络最初被广泛运用于医学领域^[5],该方法最初是在 MICCAI 2015 会议上被提出的,至今仍被大量引用。

U-Net 网络的模型最大的优点就是不需要太多的影像训练样本,就能较完成的识别出所需的种类。U-Net 网络结构由于缺少全连接层,只能够通过卷积层来预测每个被分割的图像。U-Net 结构中采用了前 4 次下采样模式和第 4 次上下采样的方式来确保可以对图像层中图像的平均每个像素尺寸大小进行更加精确地预测,卷积层图中图像的平均每个像素卷积核大小约为 3*3,每次下采样后池化图像层图会分别将

特征图层中图像的原始图像尺寸缩小约为其一半。

3 基于深度学习 U-Net 神经网络的塌陷识别

3.1 采煤沉陷典型区域遥感影像特征描述

(1) 塌陷坑

塌陷深坑影像特征为指纹状斑点或呈条索带状斑状,形状特点一般较似于长柄圆形洼地或呈近椭圆形碟状洼地。

(2) 地裂缝

地裂缝的形状各不相同,影像特征呈线状或条带状,由于研究区的植被分布不均匀,地裂缝较难识别。

(3) 滑坡和崩塌

滑坡表现为浅白色、灰白色介于或近等于的浅灰色调。崩塌主要影像特征主要表现为较浅灰、灰白色调,与岩石底周围呈现的一些较浅深色调之间形成了一个明显的色调的深差。

3.2 U-Net 网络模型处理流程

3.2.1 数据集和数据增强

在进行深度学习网络模型构建的过程中,首先要做的是制作数据集,数据集由训练的数据集、测试数据集和验证数据集组成^[6]。

本研究采用的是规则格网裁剪,规则格网裁剪属于重复率为 0 的滑动窗口裁剪,通过代码运行后,生成分辨率为 256*256 大小的图片,然后将分辨率一致的图片进行样本制作,本次研究制作样本的软件为 Labelme。在 Labelme 中将图片导入,然后根据自己需要的影像分类特征结合实地考察数据进行样本制作,由于软件的限制,只能用英文标住,本研究将地裂缝表达为 crack,塌陷坑表示为 pit,塌陷盆地表示为 basin。

由于矿区塌陷的影像特征不多,在样本制作完成后,需要对样本进行数据增强操作。通过数据增强后生成 850 张图片和对应的标签,然后按照 6:2:2 的比例随机选择 511 张图片作为训练数据集,169 张照片作为测试数据集,170 张图片作为验证数据集。

3.2.2 实验设置

本研究将使用 python 语言来进行网络仿真训练实验,通过调用 python 库中提供的深度机器学习框架和使用 Keras 搭建了改进之后的 U-Net 神经网络,将使用 Tensorflow 深度机器学习框架来作为实验后

端,使用高性能 GPU 来对网络模型进行实时加速训练。

3.2.3 算法性能评价参数

为验证本章中改进的 U-Net 网络模型对地裂缝、塌陷坑、盆地检测识别算法的性能,本研究使用混淆矩阵的分类精度评定方法来对实验评定,混淆矩阵如表 1 所示。

表 1 混淆矩阵

Real Image	Detection Result		
	Positive	Negative	Total
Positive	TP=True Positives	FN=False Negatives	TP+FN
Negative	FP=False Positives	TN=True Negatives	FP+TN
Total	TP+FP	FN+TN	—

其中:

TP:分类准确的正类;FP:被错分类为正类的负类;TN:分类准确的负类;FN:被错分类为负类的正类。

3.2.4 算法步骤

(1) 数据扩充

为解决样本数量少的问题,需要对图像进行数据增强相关操作。

(2) 图像归一化

对图像按照统一的标准进行处理,使其成为统一标准的数据。

(3) 进行模型搭建

使用在 Tensorflow 支持下的 Keras 作为框架,利用 VScode 语言进行神经网络的模型训练和测试。

(4) 模型训练

利用搭建好的模型进行将已经进行数据扩充的图像进行训练。

(5) 进行预测

对训练好的模型对图像进行预测。

3.3 模型训练和测试结果输出

3.3.1 模型训练

本研究的 U-Net 网络采用在 Tensorflow 支持下的 Keras 作为框架,利用 VScode 进行神经网络的模型训练和测试,将训练数据集在 U-Net 神经网络中完成模型训练和测试,实验环境上面叙述中已经讲到。

首先将标签中的样本类别分为地裂缝、塌陷坑、塌陷盆地和背景四类。在模型训练过程中,首先,将提前编写好 U-Net 神经网络代码导入,其次对本次实验进行相关参数设置,因参数不是一次就能设置好的,所以要经过多次试验。首先选用 Adam 优化器,初始学习率为设为 $1e-4$,设置 batch size 为 4,在训练过程中如果连续出现 3 个 epochs 值没有下降到低于历史最低值,则学习率减半。由于本次实验识别对象较难识别,设置 valloss 连续 20 轮没有下降则停止训练,经过多次模型训练,分析模型输出的识别结果,并结合精度评价指标,确定了最符合本论文要求的参数设置,然后保存最终模型文件到指定路径,具体模型训练信息见表 2。

表 2 模型训练信息

模型参数及迭代训练信息	
分离卷积核	3*3
激活函数	交叉熵函数
分类函数	softmax
优化器	Adam
评价指标	Accuracy
学习率	$Le-4$
提前终止正则参数	Patience=10
设置迭代次数	100
实际迭代次数	80
批量数据大小	Batch_size = 4
输出类别	4 (地裂缝、盆地、塌陷坑、背景)
模型文件	unet_model.hdf5

3.3.2 模型精度评估指标

根据本研究中的算法性能评价参数,并对精度评估指标分析可得,整体精度为 97.58%,大于 90%,表明此次模型训练结果较准确,结果见表 3。从三个类别的交并比与查准率结果来看,还可以发现盆地的查准率最高,这是因为盆地中有积水,反射率高,在影像中较容易被识别的原因造成的,地裂缝识别效果其次,由于大量分布在耕地中,与耕地的颜色较接近,会对机器学习带来影响,有的地沿及干枯的小水流被识别为地裂缝,这后期需要我们进行实地调查,然后进行分析,塌陷坑由于本身形状及特征的因素影响,识别的效果差于其他两类地物,因坑内有积水或长满杂草与树木,对机器学习造成较大的误判,但总体的查准

率还是比较高的,分析上述三类地物的精度指标,证明了 U-Net 网络模型适合于本次研究的研究。

表 3 精度评估指标

类别	交并比 (IOU) /%	查准率/%	整体精度/%
地裂缝	85.21	78.97	97.58
盆地	85.25	86.95	
塌陷坑	79.32	69.06	

3.3.3 研究区塌陷识别结果分析

将模型训练完成后输出的地类信息加载到 AR-CGIS 中,然后叠加北京二号卫星影像,就可以看到地裂缝、塌陷坑、塌陷盆地具体分布实况及对应的地貌信息。

图 1 为地裂缝、盆地和塌陷坑的识别结果。




图 1 地裂缝、盆地和塌陷坑的识别结果

结果输出后,选择几个具有代表性的结果图进行分析,通过上图可以明显看出来,地裂缝的识别效果不是太好,但是大多数还是可以识别出来的,因为地裂缝与耕地的遥感特征颜色较相似,有的比较小的地裂缝难以识别,分布在林地里面的地裂缝更难以识别,选取的遥感影像为 3 月份,能够明显的看到地表表面,所以地裂缝的识别还是比较准确的。塌陷盆地看出来比较规则,因为后期可能被居民修改,用作日常使用,反射率较高,识别效果较好,但是存在识别错误的现象,有的为居民自己建造的,被误识别为塌陷盆地,塌陷坑的识别整体可以,但是塌陷坑边界的识别一直是一个难题,本研究用作定性分析,不做定量分析,所以不需要对边界进行更深入的研究。

经过识别图与遥感影像对照后,我们发现鹤岗矿区整体地面塌陷比较严重,可以看到塌陷坑和地裂缝主要分布在耕地附近,地裂缝呈聚集式分布,采空区附近的地裂缝尤为明显,且裂缝程度大,大多数横跨耕地,有的深度较深,被居民填充之后继续进行庄家种植;有的则轻微沉陷,不影响耕种,受到采煤活动的明显影响,塌陷盆地主要分布在建筑物附近,由于时间的原因,塌陷盆地里面充满积水,且部分盆地被居

民修缮后用于养殖业或者积水灌溉农田,塌陷坑的分布呈散状式分布,大小不一,大部分坑内长满野草或者被居民种植树木,塌陷比较严重。

4 结论

本研究介绍了鹤岗矿区地面沉降的实际地物特征和遥其在感影像上的特征,然后对鹤岗矿区北京二号卫星影像进行预处理,预处理之后进行数据集的制作,其次对卷积神经网络 U-Net 模型进行训练,经过多次训练,确定最合适的训练参数,在精度评价的环节,通过算法性能评价参数进行评价,整体精度为 97.58%,最后进行结果输出,得到鹤岗矿区地裂缝、塌陷坑、塌陷盆地的具体分布图,可以发现盆地的查准率最高,地裂缝识别效果其次,塌陷坑由于本身形状及特征的因素影响,识别的效果差于其他两类地物,分析上述三类地物的精度指标,证明了 U-Net 网络模型适合于本次研究。

参考文献

[1]鹿献章,杨义忠,喻根,等.淮北市北区地表水体及采

空塌陷遥感调查[J].安徽地质,1997(1):82-90.

[2]杨圣军,赵燕,吴泉源,等.高分辨率遥感图像中采矿塌陷地的提取——以龙口矿区为例[J].地域研究与开发,2006(4):120-124.

[3]梁峰.基于遥感技术与深度学习的四川高陡山区典型地质灾害识别[D].成都:成都理工大学,2021.

[4]张堯.基于 InSAR 技术大同煤田沉陷区的监测与识别[D].北京:中国地质大学(北京),2020.

[5]Ronneberger O,Fischer P,Brox T.U-net: Convolutional networks for biomedical image segmentation:International Conference on Medical image computing and computer-assisted intervention[C].2015.

[6]李兴久.基于卷积神经网络的无人机遥感影像洪水水体识别和自动提取研究[D].哈尔滨:哈尔滨师范大学,2021.

Identification of Coal Mining Collapse Types Based on U-Net Neural Network

Yang Shuping

(Zhengzhou University of Science and Technology, Zhengzhou, China)

Abstract: Due to the mining and utilization of underground coal resources, large-scale goaf areas have emerged, causing extensive subsidence and posing a threat to the safety of mining operations and personnel. This article initially preprocesses remote sensing images of the Hegang mining area and compiles a dataset. Subsequently, the U-Net convolutional neural network is employed to train the model, adjust training parameters, and identify subsidence pits, ground fissures, and subsidence basins. The overall accuracy rate of 97.58% demonstrates the relatively high precision of the model training results. Consequently, detailed distribution maps of ground fissures, subsidence pits, and subsidence basins in the Hegang mining area have been obtained. It was discovered that the basin had the highest precision, followed by the recognition of ground fissures. Due to their inherent shape and characteristics, the recognition of subsidence pits was less accurate compared to the other two land features. Analyzing the accuracy indicators of these three land features confirms that the U-Net network model is suitable for this study and provides valuable basic data for the reclamation and management of goaf subsidence areas, which is of significant importance.

Key words: U-Net; deep learning; mining area monitoring; subsidence area recognition